

电子信息学中的机器学习期末作业

LHaiC

2025 年 7 月 30 日

目录

1	实验文件简介	2
2	实验过程与结果	2
2.1	数据集准备与环境配置	3
2.2	加载模型预训练权重并测试	4
2.2.1	GPDL 模型架构	4
2.2.2	模型适用性分析	5
2.2.3	评估指标	5
2.2.4	测试预训练权重	6
2.3	本地训练模型并测试	6
2.4	对训练后的模型进行量化	9
2.5	改进模型结构以提高准确率	16
2.5.1	Squeeze-and-Excitation 注意力机制	17
2.5.2	ASPP 多尺度特征提取	18
2.5.3	DoubleU-Net 双网络架构	20
2.5.4	DoubleU-Net 改进与蒸馏训练	23
2.5.5	测试结果的对比分析	26

3	实验总结与展望	27
4	附录: 权重文件测试结果	29

§1 实验文件简介

本次实验的完整文件如下列出，其中红色代表我的新建文件，蓝色代表修改的文件，若干未改动的文件未被标出：

project	项目根目录
congestion_double_gpdl	DoubleGPDL 权重
congestion_double_gpdl_distill	DoubleGPDLdistill 权重
congestion_gpdl_0.1	使用 0.1 数据训练的 GPDL 权重
congestion_gpdl_0.5	使用 0.5 数据训练的 GPDL 权重
congestion_gpdl_0.25	使用 0.25 数据训练的 GPDL 权重
congestion_gpdl_1.0	使用完整数据训练的 GPDL 权重
datasets	
build_dataset.py	新增：控制使用数据集比例的功能
files	
logs	日志文件
loss_curves	plot_loss.py 绘制的 loss 曲线图
models	
__init__.py	新增：DoubleGPDL, DoubleGPDLdistill
double_gpdl.py	DoubleGPDL 模型实现
preprocess_scripts	
quantization_results	plot_quant.py 绘制的模型量化结果
test_pths_results	test_pths.py 的结果，对应章节4
utils	
configs.py	新增若干 args
quant.py	模型量化相关代码
congestion.pth	提供的预训练模型权重
plot_loss.py	绘制损失曲线脚本
plot_quant.py	绘制量化结果脚本
test_all.py	自动测试所有权重与量化实验的脚本
test_quant.py	测试量化模型脚本
test_pths.py	测试并记录所有模型权重结果的脚本
test.py	
train.py	新增：打印日志
train_distill.py	蒸馏训练脚本

§2 实验过程与结果

本次实验的目的是基于 CircuitNet 开源项目¹完成 Congestion Prediction 任务，并且在其基础上进行模型训练、量化和拓展的探索。涉及的概念简介如下：

¹<https://github.com/circuitnet/CircuitNet>

1. 拥塞是指在布线阶段，电路的连接需求超过可用的布线资源，导致某些区域过于拥挤
2. 拥塞预测在通过在布局阶段预测可能的拥塞问题，设计师可以相应地调整元件的放置，以优化整个布局和布线方案

2.1 数据集准备与环境配置

本次实验使用的数据集是 CircuitNet-N28，参考提供的链接²下载好对应的数据集文件，解压后再使用提供的脚本 `generate_training_set.py` 构建好数据集，文件结构如下：

```
├── training_set
│   ├── congestion
│   │   ├── feature
│   │   └── label
```

项目环境的初始配置理论上只需完成以下基础安装：

- CUDA 12.9 及对应显卡驱动
- PyTorch 2.7.0
- Python 3.9

随后通过执行 `pip install -r requirements.txt`³ 安装其余依赖项。然而实际配置过程中遇到 PyTorch 2.7.0 与 `requirements.txt` 中指定 MMCV 版本的兼容性问题。

针对该兼容性问题，我们采取以下解决方案：

1. 从源码编译适配 PyTorch 2.7.0 的 MMCV 2.2.0
2. 修改项目中涉及 MMCV API 调用的兼容性代码
3. 验证各模块功能完整性

成功配置后的开发环境规格如下：

```
1 Python 3.9.21
2 GPU 0: NVIDIA GeForce RTX 5070 Ti
3 CUDA_HOME: /usr/local/cuda-12.9
4 NVCC: Cuda compilation tools, release 12.9, V12.9.41
```

²<https://circuitnet.github.io/intro/download.html#decompress-and-preprocess>

³依赖文件位于 CircuitNet 项目根目录

```

5 GCC: gcc (Ubuntu 13.3.0-6ubuntu2~24.04) 13.3.0
6 PyTorch: 2.7.0+cu128
7 torchvision: 0.22.0+cu128
8 OpenCV: 4.6.0
9 MMEEngine: 0.10.7
10 MMCV: 2.2.0

```

2.2 加载模型预训练权重并测试

2.2.1 GPDL 模型架构




Figure 1: GPDL 模型架构示意图

模型定义于 `models/gpdl.py`，采用编码器-解码器结构，主要组件如下：

编码器模块

- 输入：3 通道特征图 (256×256)
- 核心结构：
 - 卷积块：双 Conv2d+InstanceNorm+LeakyReLU(0.2) 组合
 - 下采样： 2×2 最大池化 (stride=2)
 - 输出层：Conv2d+BatchNorm+Tanh 生成 32 维特征
- 跳跃连接：保留第 2 层 64 通道特征 (h2) 用于解码器融合

解码器模块

- 特征融合：通过通道拼接（concat）整合编码器特征
- 上采样：转置卷积（ConvTranspose2d）实现 2 倍分辨率提升
- 输出层：Conv2d+Sigmoid 生成 2 通道预测结果

2.2.2 模型适用性分析

GPDL 模型架构特别适合 Congestion Prediction 任务的设计主要体现在以下四个关键方面：

首先，U-Net 式的编解码结构通过对称的下采样和上采样路径，完美匹配了从芯片布局图到拥塞热图的图像到图像转换需求。编码器通过逐步下采样捕获全局布线特征，而解码器则通过上采样恢复空间细节，这种结构天然保持了输入输出之间的空间对应关系。

其次，模型采用实例归一化 (InstanceNorm) 而非传统的批量归一化，这一设计显著提升了模型对不同芯片设计方案的适应能力。由于不同芯片设计在单元密度、布线资源分布等方面存在较大差异，InstanceNorm 通过对每个样本独立归一化，有效避免了特征分布偏移问题。

然后，跳跃连接 (skip connection) 机制的引入解决了传统编解码结构中细节丢失的痛点。通过将编码器第 2 层的 64 维特征直接传递至解码器，模型能够保留宏单元布局等关键局部细节信息，这对准确预测局部拥塞热点至关重要。

最后，输出层采用 Sigmoid 激活函数具有明确的物理意义。该函数将预测值严格约束在 [0,1] 范围内，正好对应标准化后的拥塞热图数值表示，既符合工程解释性要求，又避免了不合理的负值预测。

这种精心设计的架构使得 GPDL 模型能够同时兼顾全局特征提取和局部细节保留，在保持高效推理速度的同时，实现了芯片拥塞预测任务所需的精度和鲁棒性。

2.2.3 评估指标

NRMSE (归一化均方根误差)

$$\text{NRMSE} = \frac{1}{y_{\max} - y_{\min}} \sqrt{\frac{1}{hw} \sum_{i=1}^h \sum_{j=1}^w (y_{i,j} - \hat{y}_{i,j})^2} \quad (1)$$

其中 y 为真实值, $\hat{y}$ 为预测值。该指标衡量像素级绝对误差, 值域 $[0,1]$, 越小越好。

SSIM (结构相似性指数)

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (2)$$

其中 $C_1 = (0.01L)^2$, $C_2 = (0.03L)^2$ (L 为像素值范围)。该指标评估结构相似性, 值域 $[-1,1]$, 越大越好。

2.2.4 测试预训练权重

加载预训练权重 `congestion.pth` 后, 在测试集上获得如下结果:

```
1 (circuitnet) lhc@LHC-UBT:~/EEML/project$ python test.py --pretrained ./congestion.pth
2 ==> Loading datasets
3 ==> Building model
4 ==> Avg. NRMS: 0.0417
5 ==> Avg. SSIM: 0.8078
```

2.3 本地训练模型并测试

为了记录训练过程以及灵活修改训练使用的数据集大小, 在 `train.py` 中增加了日志保存功能, 并修改了 `datasets/build_dataset.py`。通过以下命令分别从头⁴训练不同比例数据量的模型:

```
1 python train.py --save_path ./congestion_gpdL_0.1 --data_ratio 0.1
2 python train.py --save_path ./congestion_gpdL_0.25 --data_ratio 0.25
3 python train.py --save_path ./congestion_gpdL_0.5 --data_ratio 0.5
4 python train.py --save_path ./congestion_gpdL_1.0 # 默认使用完整数据集
```

通过 `plot_loss.py` 脚本绘制的 loss 曲线如图2所示:

⁴未使用预训练权重以保证对比公平性




Figure 2: 不同数据量训练 loss 曲线对比

用如下命令测试得到的各模型，测试结果如表1所示，其中 25% 数据量的模型表现最优：

```

1 (circuitnet) lhc@LHC-UBT:~/EEML/project$ python test.py --pretrained ./congestion_gpdl_1
  .0/model_iters_200000.pth
2 ==> Loading datasets
3 ==> Building model
4 ==> Avg. NRMS: 0.0503
5 ==> Avg. SSIM: 0.7744
6 (circuitnet) lhc@LHC-UBT:~/EEML/project$ python test.py --pretrained ./congestion_gpdl_0
  .5/model_iters_200000.pth
7 ==> Loading datasets
8 ==> Building model
9 ==> Avg. NRMS: 0.0512
10 ==> Avg. SSIM: 0.7746
11 (circuitnet) lhc@LHC-UBT:~/EEML/project$ python test.py --pretrained ./congestion_gpdl_0
  .25/model_iters_200000.pth
12 ==> Loading datasets
  
```



```

13 ==> Building model
14 ==> Avg. NRMS: 0.0491
15 ==> Avg. SSIM: 0.7829
16 (circuitnet) lhc@LHC-UBT:~/EEML/project$ python test.py --pretrained ./congestion_gpd1_0
    .1/model_iters_200000.pth
17 ==> Loading datasets
18 ==> Building model
19 ==> Avg. NRMS: 0.0516
20 ==> Avg. SSIM: 0.7767

```

Table 1: 不同数据量模型的测试指标

数据比例	NRMS	SSIM
100%	0.0503	0.7744
50%	0.0512	0.7746
25%	0.0491	0.7829
10%	0.0516	0.7767

现象分析与讨论

理论上数据量越多，训练得到的模型性能越好，泛用性越强，因此在测试集上的表现也会更好，但是实验观测到与理论预期相悖的现象：当训练数据量从 100% 减少至 25% 时，模型性能反而提升，具体表现为：

- NRMS 从 0.0503 降至 0.0491
- SSIM 从 0.7744 升至 0.7829

针对该异常现象，提出以下可能解释：

1. **数据分布偏差**：随机采样的 25% 训练子集可能偶然与测试集具有更高的分布相似性。
2. **优化特性差异**：小数据量下模型可能：
 - 更早收敛至平坦极小值 (flat minima)，具有更好泛化性
 - 避免陷入完整数据训练可能带来的尖锐极小值 (sharp minima) 以及过拟合

需要指出的是，在前面我默认测试的是完成了全部 200,000 个迭代后的权重文件，然而通过后续对保存的所有权重文件的测试（见章节4），可以发现原来的现象和分析讨论有很大问题。首先取各个数据量下最好的结果列表如下：

Table 2: 不同数据量模型的最好测试指标

数据比例	Iter	NRMS	SSIM
100%	10,000	0.0459	0.7917
50%	10,000	0.0481	0.7827
25%	10,000	0.0458	0.7877
10%	50,000	0.0494	0.7816

很显然，从这个表格可以得到一个符合我们直觉的结论：训练的数据量越大，模型在测试集上的结果越好。这是因为对于一个合理的训练集、测试集的数据划分来说，它们二者的数据分布应该是类似的，所以选取完整的训练集才能让模型学习到完整的特征和良好的泛化能力，从而在测试集上取得很好的结果。

再次讨论该反常现象

通过附录4完整的权重测试结果，我们现在可以真正地分析为何会出现表格1中的反常现象。从表格2中可以看出，最好的结果均出现在较小的迭代次数中，之后随着迭代次数的增加，测试结果反而会明显下降。但是直观对比 loss 曲线2，和详细对比保存的日志，可以发现整体 loss 是一直在下降的。这说明反常现象可能是由于过拟合或者不合理的 loss 选取（默认的 MSEloss）引起的，通过后续对数据重新划分得到测试集、验证集与训练集，然后重新训练即可验证是否出现了严重的过拟合。

2.4 对训练后的模型进行量化

为了提升模型的推理效率，实际部署时经常将模型量化为低比特（如 INT8, INT4），本次实验为探索训练后对模型权重进行不同精度量化对模型准确率的影响，参考代码⁵使用 fakequant 量化，包含以下部分：

1. 分别对模型的不同组成模块单独进行量化，并探索量化不同模块对模型准确率的影响
2. 尝试对模型推理过程中的激活值进行量化，并比较量化激活值和量化权重对模型准确率的影响

⁵https://github.com/ht-zhou/binary-bert/blob/master/BinaryBERT/transformer/utils_quant.py

需要特别说明的是，本实验采用**训练后量化 (PTQ)** 策略，即在已训练完成的 FP32 模型 (congestion_gptl_1.0/model_iters_200000.pth) 基础上直接应用量化，而非在训练过程中进行量化感知训练 (QAT)。

首先简单分析一下提供的参考代码是如何实现 fakequant 量化的：

1. 核心量化器类

- SymQuantizer: 对称均匀量化器，核心公式：

$$s = \frac{2^{b-1} - 1}{\max(|x|)}, \quad x_q = \text{round}(x \cdot s) / s \quad (3)$$

将浮点数映射到 $[-2^{b-1} + 1, 2^{b-1} - 1]$ 整数域。

- AsymQuantizer: 非对称 min-max 量化器，核心公式：

$$\alpha = \max(x) - \min(x), \quad \beta = \min(x) \quad (4)$$

$$x_q = \text{round} \left(\frac{x - \beta}{\alpha + \epsilon} \cdot (2^b - 1) \right) / (2^b - 1) \cdot (\alpha + \epsilon) + \beta \quad (5)$$

- LaqQuantizer: 损失感知量化器，采用迭代优化策略：

$$\alpha^{(t)} = \frac{\sum |b^{(t-1)} \odot D \odot x|}{\sum |b^{(t-1)} \odot D|} \quad (6)$$

$$x_q = \alpha^{(T)} \cdot \text{round} \left(\text{clamp} \left(\frac{x}{\alpha^{(T)}}, -1, 1 \right) \cdot n \right) / n \quad (7)$$

其中 D 为 Hessian 近似， $n = 2^{b-1} - 1$ ，迭代 10 次收敛。

- SymLsqQuantizer/AsymLsqQuantizer: 可学习步长量化器：

$$x_q = \text{clamp} \left(\text{round} \left(\frac{x}{\alpha} \right), Q_n, Q_p \right) \cdot \alpha \quad (8)$$

$$\frac{\partial L}{\partial \alpha} = \sum (I_{small} \cdot Q_n + I_{big} \cdot Q_p + I_{middle} \cdot (-q_w + \text{round}(q_w))) \cdot \frac{\partial L}{\partial x_q} \quad (9)$$

其中 α 为可学习量化步长参数。

2. 专用量化器

- BwnQuantizer: 二值权重量化器:

$$\alpha = \frac{\|x\|_1}{|x|}, \quad x_q = \alpha \cdot \text{sign}(x) \quad (10)$$

将权重量化为 $\{-\alpha, +\alpha\}$ 二值。

- TwnQuantizer: 三值权重量化器:

$$\text{thres} = 0.7 \cdot \frac{\|x\|_1}{|x|}, \quad x_q = \begin{cases} +\alpha & \text{if } x > \text{thres} \\ -\alpha & \text{if } x < -\text{thres} \\ 0 & \text{otherwise} \end{cases} \quad (11)$$

将权重量化为 $\{-\alpha, 0, +\alpha\}$ 三值。

3. 量化层封装类

- QuantizeLinear: 量化线性层, 继承自 `nn.Linear`:

$$W_q = \text{weight_quant_fn}(W, \text{clip_param}, b_w, \text{symmetric}, \text{method}) \quad (12)$$

$$X_q = \text{act_quant_fn}(X, \text{clip_param}, b_a, \text{symmetric}, \text{method}) \quad (13)$$

$$Y = X_q \cdot W_q^T + b \quad (14)$$

支持权重和激活值联合量化, 可配置量化比特数、对称性和量化方法。

- QuantizeEmbedding: 量化嵌入层, 继承自 `nn.Embedding`:

$$E_q = \text{weight_quant_fn}(E, \text{clip_param}, b_e, \text{symmetric}, \text{method}) \quad (15)$$

$$Y = \text{embedding_lookup}(\text{input_ids}, E_q) \quad (16)$$

仅对权重进行量化, 输入为离散索引无需量化。

在这个代码的基础之上, 我实现了卷积和反卷积的 `fakequant` 类, 并且实现了配套的将模型替换成对应量化的工具函数, 代码放在 `utils/quant.py` 中, 简要分析一下我的代码:

4. 扩展量化层实现

- QuantizeConv2d: 量化卷积层, 继承自 `nn.Conv2d`, 实现卷积操作的权重和激活值量化:

$$W_q = \text{weight_quant_fn}(W_{conv}, \text{weight_clip_param}, b_w, \text{symmetric}_w, \text{method}_w, \text{layerwise}_w) \quad (17)$$

$$X_q = \text{act_quant_fn}(X, \text{input_clip_param}, b_a, \text{symmetric}_a, \text{method}_a, \text{layerwise}_a) \quad (18)$$

$$Y = \text{Conv2D}(X_q, W_q, \text{bias}, \text{stride}, \text{padding}, \text{dilation}, \text{groups}) \quad (19)$$

- QuantizeConvTranspose2d: 量化转置卷积层, 用于上采样操作的量化实现:

$$Y = \text{ConvTranspose2D}(X_q, W_q, \text{bias}, \text{stride}, \text{padding}, \text{output_padding}, \text{groups}, \text{dilation}) \quad (20)$$

- QuantizeInstanceNorm2d/QuantizeBatchNorm2d: 量化归一化层, 对归一化参数 γ 和 β 进行量化:

$$\gamma_q = \text{weight_quant_fn}(\gamma, \text{gamma_clip_param}, \text{param_bits}, \text{symmetric}_p, \text{method}_p, \text{layerwise}_p) \quad (21)$$

$$\beta_q = \text{weight_quant_fn}(\beta, \text{beta_clip_param}, \text{param_bits}, \text{symmetric}_p, \text{method}_p, \text{layerwise}_p) \quad (22)$$

$$Y = \text{Norm}(X_q, \gamma_q, \beta_q) \quad (23)$$

5. 量化参数管理与初始化

- `_create_quant_param`: 统一的量化参数创建函数, 根据量化方法自动选择合适的参

数类型：

$$\text{param} = \begin{cases} \text{nn.Parameter}([-c, +c]) & \text{if uniform + learnable} \\ \text{Tensor}([-c, +c]) & \text{if uniform + fixed} \\ \text{LsqStepSize}(1.0) & \text{if LSQ} \\ \text{None} & \text{if BWN/TWN/LAQ} \end{cases} \quad (24)$$

6. 模型转换与校准工具

- `convert_to_quantized_model`: 递归模型转换函数，支持选择性量化：

$$\text{QuantModel} = \text{RecursiveReplace}(\text{FP32Model}, \text{QuantConfig}, \text{TargetPaths}) \quad (25)$$

$$\text{TargetPaths} = \{\text{"encoder"}, \text{"decoder.conv1"}, \dots\} \quad (26)$$

该函数通过 `SUPPORTED_QUANTIZABLE_MODULES` 映射表实现自动类型匹配：

$$\text{Mapping} = \{\text{nn.Conv2d} \rightarrow \text{QuantizeConv2d}, \quad (27)$$

$$\text{nn.Linear} \rightarrow \text{QuantizeLinear}, \quad (28)$$

$$\text{nn.InstanceNorm2d} \rightarrow \text{QuantizeInstanceNorm2d}, \dots\} \quad (29)$$

- `get_default_quant_config`: 量化配置生成器，提供统一的参数管理：
- `calibrate_model_no_activation_data`: 无数据校准函数，基于权重统计信息初始化量化参数：

$$\text{clip_val}_{\text{uniform}} = \begin{cases} [-\max(|W|), +\max(|W|)] & \text{if symmetric} \\ [\min(W), \max(W)] & \text{if asymmetric} \end{cases} \quad (30)$$

$$\alpha_{\text{LSQ}} = \text{initialize_wrapper}(W, \text{num_bits}, \text{symmetric}) \quad (31)$$

为了系统性地评估不同量化策略对模型性能的影响，我实现了 `test_quant.py` 脚本，该脚本能够自动化完成多种量化实验并记录详细的实验日志。

量化测试脚本设计

`test_quant.py` 脚本采用模块化设计，主要包含以下核心功能：

- **自动化实验流程**：通过 `experiment_definitions` 列表定义 8 种不同的量化策略，包括：
 - 编码器/解码器独立量化（实验 1-2）
 - 编码器-解码器联合量化（实验 3）
 - 仅激活值量化（实验 4）
 - 全量化（实验 5）
 - 分层量化：卷积层、转置卷积层、归一化层（实验 6-8）
- **灵活的比特数配置**：通过命令行参数 `-quant_bits` 动态设置量化比特数，默认为 8-bit
- **详细的日志记录**：每次实验都会生成时间戳格式的日志文件，记录：
 - 量化配置参数
 - 目标模块路径
 - 性能指标结果
 - 实验执行时间

实验执行流程

脚本的核心执行流程如下：

1. **基线准备**：加载预训练的 FP32 模型作为量化基准
2. **配置生成**：为每个实验生成专门的量化配置
3. **模型转换**：使用 `convert_to_quantized_model` 函数将指定模块替换为量化版本
4. **参数校准**：通过 `calibrate_model_no_activation_data` 函数初始化量化参数
5. **性能评估**：在完整测试集上评估量化模型的 NRMS 和 SSIM 指标
6. **结果记录**：将所有实验结果保存至结构化日志文件

我分别进行 INT8 和 INT4 的实验⁶，然后使用脚本 `plot_quant.py` 绘制了对比图3

```
1 python test_quant.py --pretrained ./congestion_gpd1.0/model_iters_200000.pth # 默认量化到 INT8
2 python test_quant.py --pretrained ./congestion_gpd1.0/model_iters_200000.pth --quant_bits 4
```




Figure 3: PTQ results

基于量化实验结果和热力图分析，我对量化效果进行了系统性评估，主要发现如下：

- 量化精度与性能关系符合预期：**横向对比显示，INT8 量化在所有指标上均优于 INT4 量化，但略逊于原始 FP32 模型（NRMS: 0.0503, SSIM: 0.7744）。这一结果印证了量化理论预期：更高的比特数保留更多信息，因此性能损失更小。
- 模块量化敏感性存在显著差异：**编码器-解码器模块对量化表现出不同的敏感性。仅

⁶这里我是基于之前从头训练的模型进行量化，而非基于提供的预训练模型

量化编码器 (SSIM: 0.7744) 表现优于仅量化解码器 (SSIM: 0.7738), 而同时量化两者时性能进一步下降 (SSIM: 0.7737)。造成这种现象的原因可能是:

- **特征处理层次不同:** 编码器主要提取低级视觉特征 (边缘、纹理), 对量化误差具有更强的容错性; 而解码器承担精细的空间重建任务, 量化误差会直接影响最终输出质量
- **误差传播机制:** 解码器位于网络后端, 编码器的量化误差经过前向传播会被逐层放大, 导致联合量化时性能明显下降

3. **激活值量化导致严重性能退化:** 激活值量化实验 (实验 4-5) 呈现了显著的性能下降, SSIM 从 0.77+ 骤降至 0.44-0.47, NRMS 从 0.050+ 急升至 0.084+。造成这种严重退化的根本原因包括:

- **量化实现机制差异:** 权重量化虽然压缩存储精度, 但计算过程中仍保持 FP32 精度; 而激活值量化直接将中间计算结果降至 4/8 位, 信息损失更为直接
- **动态信息损失累积:** 激活值承载网络的动态计算状态, 量化引起的信息损失会在层间传播并不断累积
- **非线性函数的放大效应:** LeakyReLU、Sigmoid 等非线性激活函数对输入精度高度敏感, 量化误差经过非线性变换后被进一步放大

4. **细粒度权重量化展现良好可行性:** 针对不同层类型的专项量化实验 (实验 6-8) 进一步证实了权重量化的实用性。实验结果显示, 无论是卷积层、转置卷积层还是归一化层的单独量化, 都能在保持合理性能的同时实现模型压缩。

这些结果充分表明权重量化具有优异的精度-效率平衡特性, 相比于激活值量化几乎不会对模型性能造成实质性影响。

这些发现为电路拥塞预测模型的实际部署提供了重要的量化指导原则, 能够在保持预测精度的前提下实现显著的模型压缩和推理加速效果。

2.5 改进模型结构以提高准确率

为了提升电路拥塞预测的准确性, 我在原始 GPDL 模型的基础上引入了多项深度学习领域的先进技术, 包括注意力机制、多尺度特征提取和双网络架构。这些改进旨在增强模型对关键特征的感知能力和空间细节的保持能力。

2.5.1 Squeeze-and-Excitation 注意力机制

理论基础与设计动机

Squeeze-and-Excitation (SE) 模块通过显式建模通道间的相互依赖关系，自适应地重新校准通道特征响应。在电路拥塞预测任务中，不同通道可能代表不同类型的布线特征（如水平布线、垂直布线、过孔等），SE 机制能够自动学习这些特征的重要性权重。




Figure 4: SE Block

数学公式与实现

SE 模块的核心操作包括 Squeeze 和 Excitation 两个步骤：

$$\text{Squeeze: } z_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W x_c(i, j) \quad (32)$$

$$\text{Excitation: } s = \sigma(W_2 \delta(W_1 z)) \quad (33)$$

$$\text{Scale: } \tilde{x}_c = s_c \cdot x_c \quad (34)$$

其中 z_c 为第 c 通道的全局平均池化结果， $W_1 \in \mathbb{R}^{\frac{C}{r} \times C}$ 和 $W_2 \in \mathbb{R}^{C \times \frac{C}{r}}$ 为全连接层权重， r 为降维比率， δ 为 ReLU 激活函数， σ 为 Sigmoid 函数。

代码实现如下：

```

1 class SEBlock(nn.Module):
2     def __init__(self, channel: int, reduction: int = 8):
3         super().__init__()
4         self.avg_pool = nn.AdaptiveAvgPool2d(1)
5         self.fc = nn.Sequential(
6             nn.Linear(channel, channel // reduction, bias=False),
7             nn.ReLU(inplace=True),
8             nn.Linear(channel // reduction, channel, bias=False),
9             nn.Sigmoid()
10        )

```

```

11
12 def forward(self, x: torch.Tensor) -> torch.Tensor:
13     b, c, _, _ = x.size()
14     y = self.avg_pool(x).view(b, c) # Squeeze
15     y = self.fc(y).view(b, c, 1, 1) # Excitation
16     return x * y.expand_as(x)      # Scale

```

在 DoubleGPD 中, SE 模块被集成到 ConvBlock 中, 通过 `use_se_in_stages` 参数控制在哪些阶段启用 SE 注意力机制。

2.5.2 ASPP 多尺度特征提取

理论基础与设计动机

Atrous Spatial Pyramid Pooling (ASPP) 通过并行的空洞卷积分支捕获多尺度上下文信息。在电路布局中, 拥塞模式可能在不同尺度上表现出不同特征: 局部的单元密集区域和全局的布线瓶颈区域, ASPP 能够同时感知这些多尺度特征。




Figure 5: ASPP

数学公式与实现

ASPP 模块包含多个并行分支, 每个分支采用不同的空洞率:

$$\text{ASPP}(x) = \text{Concat}[\text{Conv}_{1 \times 1}(x), \quad (35)$$

$$\text{AtrousConv}_{3 \times 3}^{(r_1)}(x), \quad (36)$$

$$\text{AtrousConv}_{3 \times 3}^{(r_2)}(x), \quad (37)$$

$$\text{AtrousConv}_{3 \times 3}^{(r_3)}(x), \quad (38)$$

$$\text{ImagePooling}(x)] \quad (39)$$

其中空洞卷积的感受野计算为：

$$\text{Receptive Field} = k + (k - 1) \times (r - 1) \quad (40)$$

其中 k 为卷积核大小， r 为空洞率。

核心实现代码：

```

1 class ASPP(nn.Module):
2     def __init__(self, in_channels: int, out_channels: int,
3                 atrous_rates: List[int] = [6, 12, 18]):
4         super().__init__()
5         num_branches = len(atrous_rates) + 2 # +1x1 conv +image pooling
6         branch_channels = max(1, out_channels // num_branches)
7
8         branches = []
9         # 1x1 convolution branch
10        branches.append(nn.Sequential(
11            nn.Conv2d(in_channels, branch_channels, kernel_size=1, bias=False),
12            nn.InstanceNorm2d(branch_channels, affine=True),
13            nn.LeakyReLU(0.2, inplace=True)
14        ))
15
16        # Atrous convolution branches
17        for rate in atrous_rates:
18            branches.append(ASPPConv(in_channels, branch_channels, rate))
19
20        # Image pooling branch
21        branches.append(ASPPPooling(in_channels, branch_channels))
22
23        self.convs = nn.ModuleList(branches)
24        self.project = nn.Sequential(
25            nn.Conv2d(len(branches) * branch_channels, out_channels,
26                    kernel_size=1, bias=False),
27            nn.InstanceNorm2d(out_channels, affine=True),
28            nn.LeakyReLU(0.2, inplace=True),
29            nn.Dropout2d(0.05)

```

30

)

在 DoubleGPD L 中,ASPP 被集成到编码器的瓶颈层,通过 `encoder_use_aspp_bottleneck=True` 启用。

2.5.3 DoubleU-Net 双网络架构

理论基础与设计动机

DoubleU-Net 架构采用级联的双网络设计,第一个网络生成注意力掩码,第二个网络在掩码引导下进行精细预测。这种设计的核心思想是分阶段处理:先识别重要区域,再进行详细分析。




Figure 6: Double U-net

数学公式与网络流程

DoubleGPD L 的前向传播过程可以表示为:

$$M = \text{Net}_1(X) \quad (\text{Mask Generation}) \quad (41)$$

$$X' = X \odot M \quad (\text{Element-wise Modulation}) \quad (42)$$

$$Y = \text{Net}_2(X') \quad (\text{Final Prediction}) \quad (43)$$

其中 $X \in \mathbb{R}^{B \times 3 \times H \times W}$ 为输入特征图, $M \in \mathbb{R}^{B \times 1 \times H \times W}$ 为注意力掩码, $\odot$ 表示逐元素相乘 (广播机制), $Y \in \mathbb{R}^{B \times 2 \times H \times W}$ 为最终预测结果。

核心实现代码:

```
1 class DoubleGPDL(nn.Module):
2     def __init__(self, in_channels: int = 3, out_channels: int = 2, ...):
3         super().__init__()
4         # Net1: 生成注意力掩码
5         self.net1 = GPDL(in_channels=in_channels,
6                           out_channels=1, **net1_params)
7         # Net2: 基于掩码进行精细预测
8         self.net2 = GPDL(in_channels=in_channels,
9                           out_channels=out_channels, **net2_params)
10
11     def forward(self, x_original: torch.Tensor):
12         out_net1_mask = self.net1(x_original)      # 生成掩码
13         input_net2 = x_original * out_net1_mask    # 掩码调制
14         out_net2_final = self.net2(input_net2)     # 最终预测
15         return out_net2_final
```

网络配置优化

为了最大化性能, 我采用非对称双网络设计策略, 针对两个子网络的不同功能进行差异化配置:

Table 3: DoubleGPDL 双网络配置对比

配置项	Net1 (掩码生成)	Net2 (精细预测)	设计理念
输出通道数	1	2	Net1 生成单通道注意力掩码
编码器基础通道数	48	64	Net2 需要更强特征表达能力
编码器阶段数	3	3	统一深度, 增强特征层次
瓶颈通道倍数	1.5	2.0	Net2 瓶颈容量更大
SE 使用策略 (编码器)	[X, ✓, ✓]	[X, ✓, ✓]	深层启用注意力机制
SE 使用策略 (解码器)	[X, X, ✓]	[X, ✓, ✓]	Net2 解码器更多注意力
SE 约简比	4	4	统一强注意力表达
ASPP 使用	X	✓	Net1 保持简洁, Net2 多尺度增强
ASPP 空洞率	-	[2,4,8,16]	更密集的感受野配置
解码器通道序列	[96,48,24]	[128,64,32]	Net2 高容量解码

这种精心设计的非对称配置使 DoubleGPDL 在保持推理效率的同时, 实现了显著的性

能提升，特别适合电路拥塞预测这类需要兼顾全局感知和局部精度的复杂视觉任务。

实验结果与性能分析

通过如下命令训练并测试上述 DoubleGPDL 模型，得到结果如下，通过 `plot_loss.py` 绘制得到 loss 曲线图7。

```
1 (circuitnet) lhc@LHC-UBT:~/EEML/project$ python test.py --pretrained ./
   congestion_double_gpdl/model_iters_200000.pth --model_type DoubleGPDL
2 ==> Loading datasets
3 ==> Building model
4 ==> Avg. NRMS: 0.0468
5 ==> Avg. SSIM: 0.7972
```




Figure 7: DoubleGPDL 的 loss 曲线

将 DoubleGPDL 的指标与先前的一些模型进行对比，在表4中展示了详细的性能对比结果。

Table 4: 不同模型性能对比

模型	NRMS	SSIM
预训练 GPDL	0.0417	0.8078
全量数据训练 GPDL	0.0503	0.7744
1/2 数据训练 GPDL	0.0512	0.7746
1/4 数据训练 GPDL	0.0491	0.7829
1/10 数据训练 GPDL	0.0516	0.7767
DoubleGPDL	0.0468	0.7972

和表格1一样，这里选取的也是训练完整的 200,000 个迭代次数后的权重，因此结果具有误导性，在完成模型改进的进一步尝试后，我会结合附录4中完整的权重测试结果进行详细的分析。

2.5.4 DoubleU-Net 改进与蒸馏训练

很显然，先前改进得到的 DoubleGPDL 模型的测试结果与提供的 GPDL 预训练模型的相比还是很不令人满意，于是让我们先分析一下现有模型和训练方法的缺陷，借此寻求更大的改进空间。

1. 观察附录4中完整的权重测试结果，会发现普通 GPDL 模型的测试结果会在前几个迭代次数后迅速变差，而 DoubleGPDL 模型的测试结果几乎不变，但是二者的 MSEloss 都在持续下降。
2. 目前选取的 DoubleGPDL 模型结构的参数量巨大，对于较小的训练集来说有训练不足和过拟合的风险。

从这两点分析中，我得到了以下改进思路：

1. 增加 Dropout 层进行正则化，提高模型的泛化能力，减少过拟合风险。
2. 减小模型参数量，采用非对称结构，Unet1 采用轻量架构进行粗粒度分析，Unet2 模仿原来的 GPDL 结构。
3. 修改正向传播策略，从直接 mask 相乘，改为使用一个可以学习的融合系数，增加 Unet2 输入的丰富度。

4. 使用提供的预训练 GPDL 权重进行蒸馏训练，首先 1w 个 iter 使用相对于 Ground Truth 的 MSELoss 进行热身训练，随后的 1w 个 iter 只用相对于教师模型的 MSELoss 进行蒸馏训练，剩余的 18w 个 iter 采用相对于教师模型和 Ground Truth 的混合 MSELoss 进行蒸馏训练。

为了防止这部分的代码对原来的代码造成污染，我在 `double_gpdl.py` 中新建了一个 `DoubleGPDLdistill` 类，并且将蒸馏训练的代码放在了另外的 `train_distill.py` 文件中，训练使用的命令如下：

```
1 python train_distill.py --save_path ./congestion_double_gpdl_distill --model_type
   DoubleGPDLdistill --distill --teacher_model_type GPDL --teacher_pretrained ./
   congestion.pth
```

使用的 loss 函数如下：

```
1 class DistillationLoss(nn.Module):
2     def __init__(self, loss_weight=100.0, alpha=0.8, reduction='mean', sample_wise=False):
3         super().__init__()
4         self.loss_weight = loss_weight
5         self.alpha = alpha
6         self.reduction = reduction
7         self.sample_wise = sample_wise
8
9     def forward(self, student_output, teacher_output=None, ground_truth=None, weight=None
10                , **kwargs):
11         if teacher_output is None:
12             if ground_truth is not None:
13                 total_loss = mse_loss(
14                     student_output,
15                     ground_truth,
16                     weight=weight,
17                     reduction=self.reduction,
18                     sample_wise=self.sample_wise
19                 )
20             else:
21                 raise ValueError("Both teacher_output and ground_truth cannot be None")
22         else:
```

```
22         distill_loss = mse_loss(  
23             student_output,  
24             teacher_output.detach(),  
25             weight=weight,  
26             reduction=self.reduction,  
27             sample_wise=self.sample_wise  
28         )  
29  
30         if ground_truth is not None:  
31             gt_loss = mse_loss(  
32                 student_output,  
33                 ground_truth,  
34                 weight=weight,  
35                 reduction=self.reduction,  
36                 sample_wise=self.sample_wise  
37             )  
38             total_loss = self.alpha * distill_loss + (1 - self.alpha) * gt_loss  
39         else:  
40             total_loss = distill_loss  
41  
42         return self.loss_weight * total_loss
```

训练得到的 loss 曲线如下图：




Figure 8: DoubleGPDLdistill 的 loss 曲线

2.5.5 测试结果的对比分析

将 DoubleGPDLdistill 的指标与先前的模型进行对比，在表5中展示了详细的测试结果，这里都是选取附录4中各自最好的迭代次数的结果。

Table 5: 不同模型的最好性能对比

模型	Iter	NRMS	SSIM
预训练 GPDL	-	0.0417	0.8078
全量数据训练 GPDL	10,000	0.0459	0.7917
1/2 数据训练 GPDL	10,000	0.0481	0.7827
1/4 数据训练 GPDL	10,000	0.0458	0.7877
1/10 数据训练 GPDL	50,000	0.0494	0.7816
DoubleGPDL	160,000	0.0466	0.7976
DoubleGPDLdistill	130,000	0.0462	0.7965

DoubleGPDL 和 DoubleGPDLdistill 并没有打败预训练的 GPDL 模型，甚至也没有全方位地碾压自训练的 GPDL 模型，这不免让人有点沮丧。但是需要指出的是，基于同样的模型架构，自训练的 GPDL 模型与预训练 GPDL 模型相比都相差甚远，这种差距可能源于训练数据集、训练策略、Loss 函数等各种参数之间差异，因此和它的比较是没有什么学习意义的（除非我们能够知道预训练模型的具体训练过程）。

而虽然 DoubleGPD L 和 DoubleGPD Ldistill 并不能在两个指数上都胜过自训练的 GPD L 模型，但是它们至少在 SSIM 指标上有一定进步，且 NRMS 指标的差距不大，此外从附录4中可以看出，这两个模型的性能更加稳定，也更有鲁棒性。我相信经过对 DoubleGPD L 的模型架构和训练过程中的各种参数的合理调整以后，肯定会取得比目前的结果更加优异的成绩。

§3 实验总结与展望

本次实验围绕 CircuitNet 的拥塞预测任务，完成了一次从复现、分析到创新的完整研究闭环。我们不仅成功训练了基线 GPD L 模型，更深入探索了数据效率、模型量化和架构改进等多个关键方向。核心成果与关键洞见总结如下：

- 揭示了基线模型的过拟合问题与评估陷阱。**实验初期观察到“25% 数据训练的模型优于全量数据”的反常现象。通过对附录4中所有迭代节点的权重进行全面测试，我们揭示了其根本原因：标准的 GPD L 模型在训练早期（约 10,000 次迭代）达到性能峰值后，便迅速陷入严重的过拟合，尽管训练损失持续下降，但测试集指标（NRMS/SSIM）却不断恶化。这一发现不仅解释了最初的异常现象，更凸显了在模型评估中进行全面、多阶段测试的重要性，避免仅凭最终权重得出片面结论。
- 系统性评估了训练后量化（PTQ）策略并得出实用性结论。**通过对 8 种不同量化方案的系统性测试，我们验证了：
 - **权重量化的高度可行性：**将权重（卷积层、归一化层等）量化至 INT8 甚至 INT4，对模型性能的负面影响微乎其微，展现了优异的精度-效率平衡。
 - **激活值量化的巨大风险：**对激活值进行量化会导致灾难性的性能退化（SSIM 从 0.77+ 骤降至 0.44），这揭示了在没有量化感知训练的情况下，直接量化中间计算结果的巨大风险。
 - **模块的差异化敏感度：**解码器模块对量化误差比编码器更敏感，这为未来进行混合精度量化提供了明确的指导方向。
- 设计并验证了改进架构 DoubleGPD L 的有效性与稳定性。**针对基线模型的过拟合和性能瓶颈，我们设计了集成了 SE 注意力机制、ASPP 多尺度特征提取和双网络级联

结构的 DoubleGPDL 模型。实验结果（表5）表明，该模型在性能上显著优于我们自行训练的 GPDL 模型（SSIM 从 0.7917 提升至 0.7976）。更重要的是，其性能在整个训练过程中表现出高度的稳定性，有效缓解了基线模型的早衰问题，证明了架构改进在提升模型鲁棒性上的关键作用。

4. **通过知识蒸馏进一步优化，但与预训练模型仍存差距。**我们进一步尝试使用知识蒸馏策略训练 DoubleGPDLdistill 模型，并取得了与 DoubleGPDL 相当的优异性能。尽管我们的最佳模型（NRMS: 0.0461, SSIM: 0.7976）已显著优于自训练的基线，但与官方提供的预训练 GPDL（NRMS: 0.0417, SSIM: 0.8078）相比仍存在差距。我们推断，这种差距主要源于未知的训练策略，如特定的学习率调度、数据增强方法或更优化的损失函数，而非单纯的架构差异。

未来展望：基于本次实验的发现与局限，未来的改进方向十分明确。首先，应引入验证集和早停（Early Stopping）机制，从根本上解决过拟合问题，并进行系统的超参数搜索以充分发掘现有模型的潜力。其次，可以探索量化感知训练（QAT），以期在激活值量化上取得突破，实现更极致的模型压缩。最后，可以继续探索更先进的网络架构，如基于 Transformer 的视觉模型，以期在性能上超越现有 SOTA 水平。

§4 附录: 权重文件测试结果

congestion_gpdl_1.0_results

Table 6: Results from congestion_gpdl_1.0_results.txt

Iterations	NRMS	SSIM
10,000	0.0459	0.7917
20,000	0.0480	0.7811
30,000	0.0470	0.7889
40,000	0.0473	0.7874
50,000	0.0478	0.7850
60,000	0.0487	0.7805
70,000	0.0488	0.7802
80,000	0.0494	0.7782
90,000	0.0493	0.7771
100,000	0.0495	0.7766
110,000	0.0492	0.7793
120,000	0.0497	0.7768
130,000	0.0495	0.7770
140,000	0.0497	0.7769
150,000	0.0499	0.7758
160,000	0.0501	0.7749
170,000	0.0502	0.7749
180,000	0.0502	0.7747
190,000	0.0502	0.7745
200,000	0.0503	0.7744

congestion_gddl_0.5_results

Table 7: Results from congestion_gddl_0.5_results.txt

Iterations	NRMS	SSIM
10,000	0.0481	0.7827
20,000	0.0503	0.7755
30,000	0.0527	0.7684
40,000	0.0513	0.7736
50,000	0.0511	0.7744
60,000	0.0501	0.7784
70,000	0.0513	0.7720
80,000	0.0512	0.7732
90,000	0.0511	0.7735
100,000	0.0510	0.7748
110,000	0.0510	0.7749
120,000	0.0508	0.7758
130,000	0.0506	0.7773
140,000	0.0510	0.7755
150,000	0.0510	0.7757
160,000	0.0511	0.7746
170,000	0.0512	0.7746
180,000	0.0512	0.7748
190,000	0.0512	0.7747
200,000	0.0512	0.7746

congestion_gddl_0.25_results

Table 8: Results from congestion_gddl_0.25_results.txt

Iterations	NRMS	SSIM
10,000	0.0458	0.7877
20,000	0.0485	0.7819
30,000	0.0488	0.7811
40,000	0.0486	0.7834
50,000	0.0482	0.7848
60,000	0.0477	0.7870
70,000	0.0482	0.7856
80,000	0.0481	0.7856
90,000	0.0482	0.7860
100,000	0.0482	0.7854
110,000	0.0484	0.7853
120,000	0.0486	0.7848
130,000	0.0488	0.7844
140,000	0.0490	0.7831
150,000	0.0488	0.7841
160,000	0.0489	0.7838
170,000	0.0490	0.7832
180,000	0.0491	0.7832
190,000	0.0491	0.7830
200,000	0.0491	0.7829

congestion_gddl_0.1_results

Table 9: Results from congestion_gddl_0.1_results.txt

Iterations	NRMS	SSIM
10,000	0.0523	0.7698
20,000	0.0506	0.7762
30,000	0.0501	0.7788
40,000	0.0509	0.7795
50,000	0.0494	0.7816
60,000	0.0502	0.7806
70,000	0.0505	0.7805
80,000	0.0500	0.7818
90,000	0.0504	0.7805
100,000	0.0505	0.7802
110,000	0.0504	0.7814
120,000	0.0508	0.7794
130,000	0.0510	0.7776
140,000	0.0511	0.7776
150,000	0.0513	0.7779
160,000	0.0514	0.7771
170,000	0.0516	0.7770
180,000	0.0517	0.7767
190,000	0.0516	0.7767
200,000	0.0516	0.7767

congestion_double_gpdl_results.

Table 10: Results from congestion_double_gpdl_results.txt

Iterations	NRMS	SSIM
10,000	0.0470	0.7904
20,000	0.0472	0.7902
30,000	0.0473	0.7895
40,000	0.0465	0.7935
50,000	0.0466	0.7964
60,000	0.0468	0.7961
70,000	0.0468	0.7945
80,000	0.0465	0.7973
90,000	0.0469	0.7956
100,000	0.0469	0.7951
110,000	0.0468	0.7958
120,000	0.0466	0.7973
130,000	0.0467	0.7973
140,000	0.0468	0.7976
150,000	0.0466	0.7974
160,000	0.0466	0.7976
170,000	0.0468	0.7970
180,000	0.0467	0.7972
190,000	0.0468	0.7971
200,000	0.0468	0.7972

congestion_double_gpdl_distill_results

Table 11: Results from congestion_double_gpdl_distill_results.txt

Iterations	NRMS	SSIM
10,000	0.0469	0.7892
20,000	0.0465	0.7939
30,000	0.0463	0.7941
40,000	0.0463	0.7939
50,000	0.0465	0.7935
60,000	0.0463	0.7956
70,000	0.0463	0.7955
80,000	0.0462	0.7958
90,000	0.0462	0.7956
100,000	0.0463	0.7956
110,000	0.0465	0.7954
120,000	0.0466	0.7949
130,000	0.0462	0.7965
140,000	0.0463	0.7957
150,000	0.0461	0.7958
160,000	0.0462	0.7956
170,000	0.0464	0.7954
180,000	0.0463	0.7954
190,000	0.0462	0.7958
200,000	0.0463	0.7956